Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

# Разработка ПО для анализа исходного кода на основе векторного представления AST.

Научный руководитель: Бородин А. А.
Выполнил: Кулагин Р. А.

Москва, 2020г.

# План

1. Архитектура сети (code2vec)
2. Рандомная обфускация, j->builder
3. Единый датасет
4. Метрики
5. Умная обфускация, *->variable, текущее
6. Презентация
7. Проблемы нейросети (итоговые)

# code2vec

Эта же архитектура легла в основу проекта.

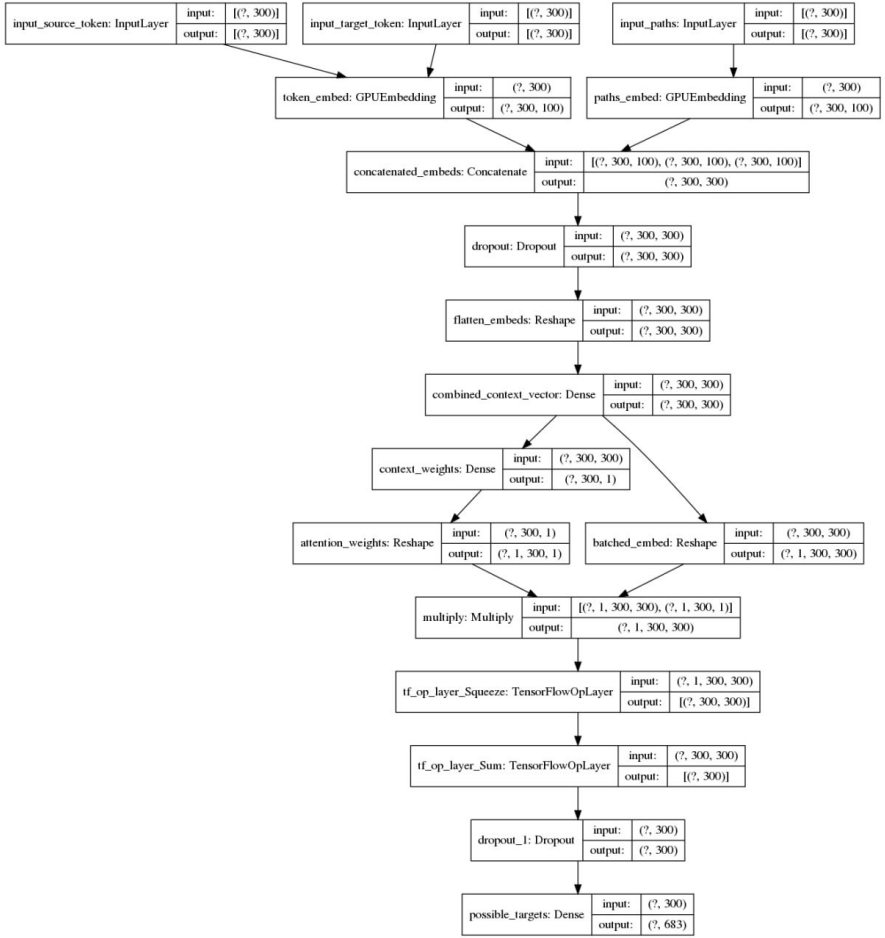

# Abstract Syntax Tree

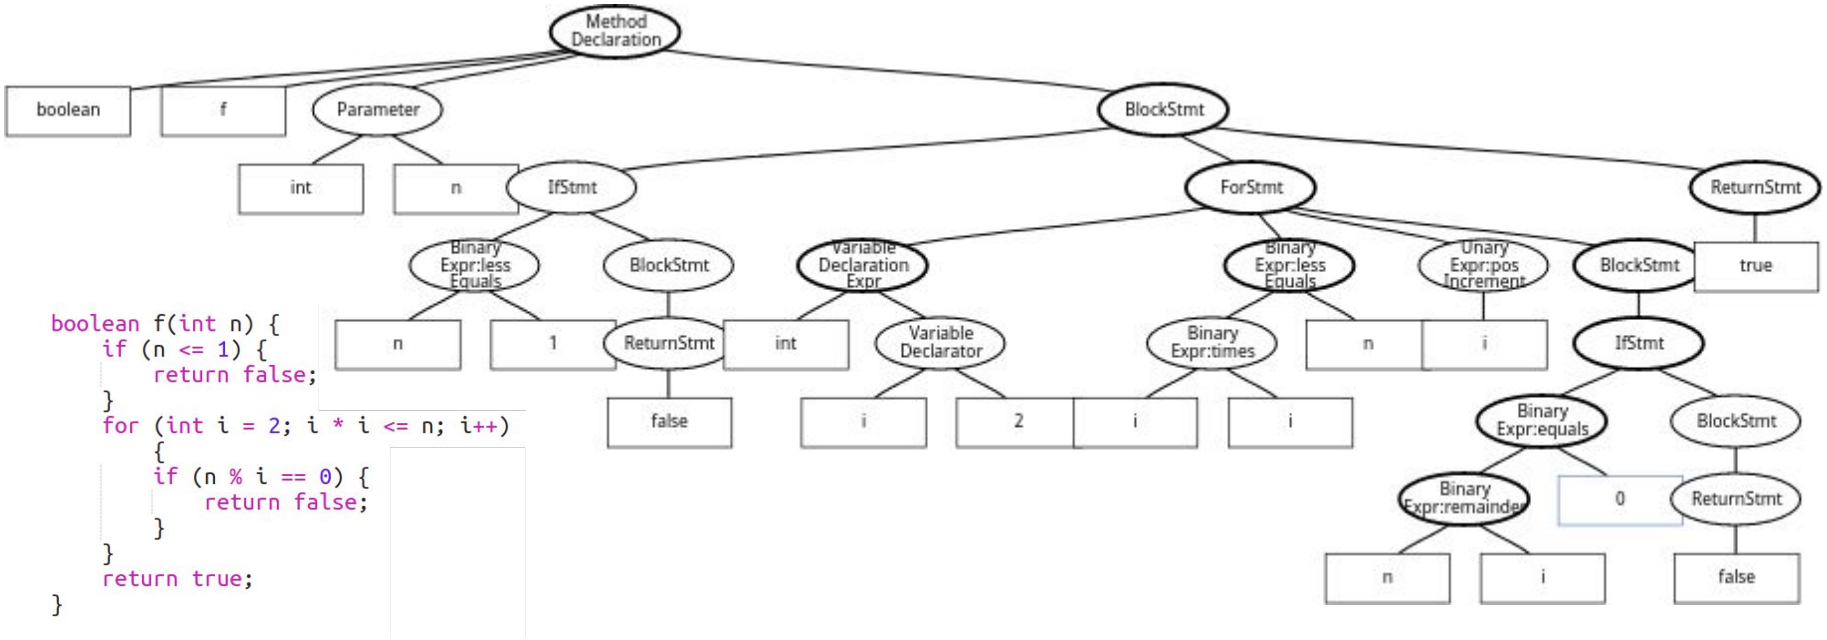


```
boolean f(int n) {
    if (n <= 1) {
        return false;
    }
    for (int i = 2; i * i <= n; i++)
        {
        if (n % i == 0) {
            return false;
        }
    }
    return true;
}
```

В листьях дерева всегда находятся имена классов, переменных, функций, константы.

# Что делает эта функция?

```
public static void foo(int[] fsbd) {
    Integer sjkf= fsbd.length;
    for (int fsak = 0; i < (sjkf - 1); fsak++)
        for (int fa = 0; < ((sjkf - i) - 1); fa++)
            if (fsbd[fa] > fsbd[fa + 1]) {
                int fsck = fsbd[fa];
                fsbd[fa] = fsbd[fa + 1];
                fsbd[fa + 1] = fsck;
            }
}
```

Пример кода до деобфускации

```
public static void sort(int[] array) {
    Integer length = array.length;
    for (int i = 0; i < (length - 1); i++)
        for (int j = 0; j < ((length - i) - 1); j++)
            if (array[j] > array[j + 1]) {
                int value = array[j];
                array[j] = array[j + 1];
                array[j + 1] = value;
            }
}
```

Пример кода после работы программы (деобфускации)

# code2vec слишком опирается на имена переменных

```
void f() {
   boolean done = false;
   while (!done) {
      if (remaining() <= 0) {
         done = true;
      }
   }
}
```

(Correct) Predictions:

| | |
|---|---|
| **done** | 34.27% |
| **isDone** | 29.79% |
| **goToNext** | 12.81% |
| **current** | 8.93% |

```
int f(int n) {
   if (n == 0) {
      return 1;
   } else {
      return n * f(n-1);
   }
}
```

(Correct) Predictions:

| | |
|---|---|
| **factorial** | 47.73% |
| **fact** | 22.99% |
| **fac** | 9.15% |
| **spaces** | 7.11% |

```
void f() {
   boolean don = false;
   while (!don) {
      if (remaining() <= 0) {
         don = true;
      }
   }
}
```

(Incorrect) Predictions:

| | |
|---|---|
| **createMessage** | 75.07% |
| **checkMessage** | 16.25% |
| **compareTo** | 8.55% |
| **putMessage** | 0.06% |

```
int f(int total) {
   if (total == 0) {
      return 1;
   } else {
      return total * f(total-1);
   }
}
```

(Incorrect) Predictions:

| | |
|---|---|
| **getTotal** | 84.21% |
| **total** | 4.06% |
| **average** | 2.31% |
| **setTotal** | 2.25% |

# Нужно обфусцировать!

Случайным образом. Все переменные заменяются на произвольную строку. (obfuscated-code2vec)

- Много листьев, не несущих в себе никакого смысла.
- Нет связи листьев, используемых для обучения и работы.
- Никак не учитываются имена классов, функций, константы.
- Больше параметров нейросети, обучение идет долго.

Версия с минимальным количество ограничений, которая у меня запустилась имела более 350 миллионов параметров (у Сбер ruGPT-3 их всего в 2 раза больше) и практически не работала.

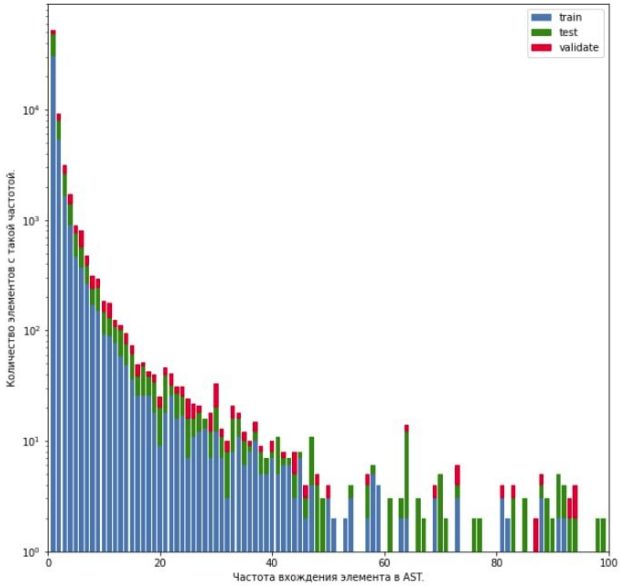


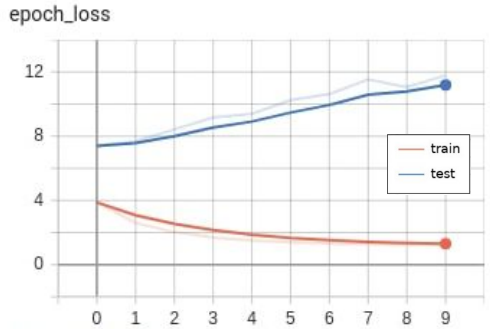


График функции потерь для переменных.

Точность при обучении 77%

# Единый датасет

Разные проекты, тестовый и обучающий датасета не связаны.

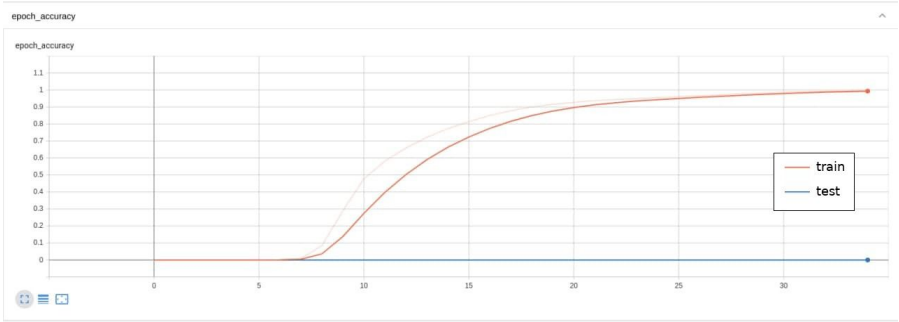


Тестовый датасет – 10% данных, изъятых из обучающего датасета.

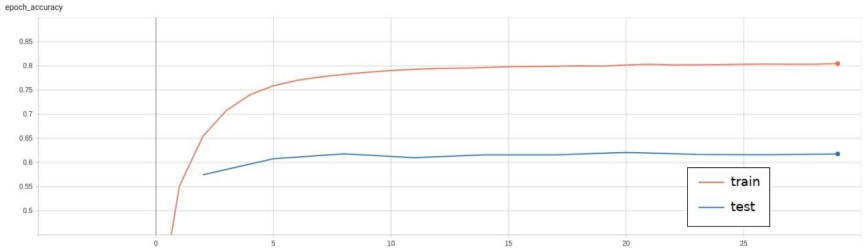

# Как оценивать результаты работы нейросети?

Стандартный Accuracy

$$\frac{TP+TN}{TP+FN+FP+TN}$$

Учитываются только точные попадания (ТОП-1) и верно предсказанные непопадания

Самописный Precision

$$\frac{TP}{TP+FP}$$

Попадания в ТОП-5 считаются успешными.

# Меняем обфускацию

Замена, основываясь на типе листа AST.

- Мало листьев. Имена классов – CLASS_NAME, функций – FUNC, константы – CONSTANT.
- Имена встроенных типов и некоторые константы (0, 1, INT_MAX, NaN, null, "") можно не обфусцировать.
- Одинаковые листья и для обучения, и для работы.

График функции потерь для нейронной сети для определения идентификаторов переменных, обученной на обфусцированных переменных со случайным индексом (в пределах 50).

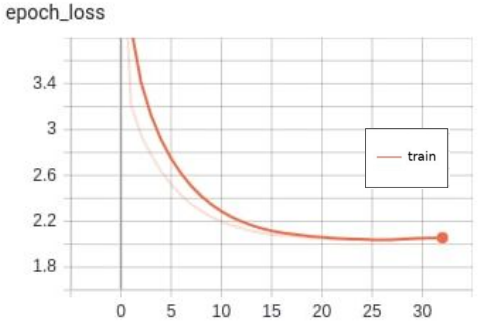


Переменные. Точность: train 15%

График функции потерь для нейронной сети для определения идентификаторов переменных, обученной на обфусцированных переменных без индекса.

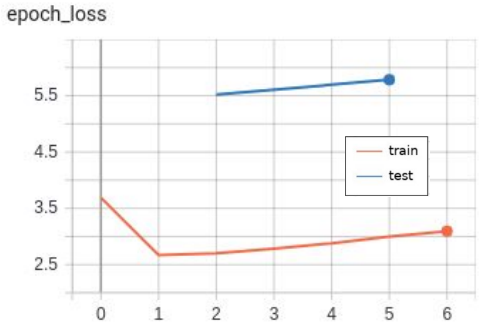


Переменные.

Точность: train 46%, test 30%

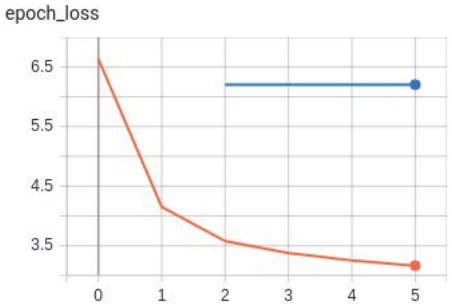


Функции.

Точность: train 46%, test 35%

# Демонстрация.

# Особенности архитектуры

Эмбеддинги учатся очень быстро, а dense учится долго. В результате мы имеем веса эмбеддингов, обучившихся под случайные веса слоев dense.

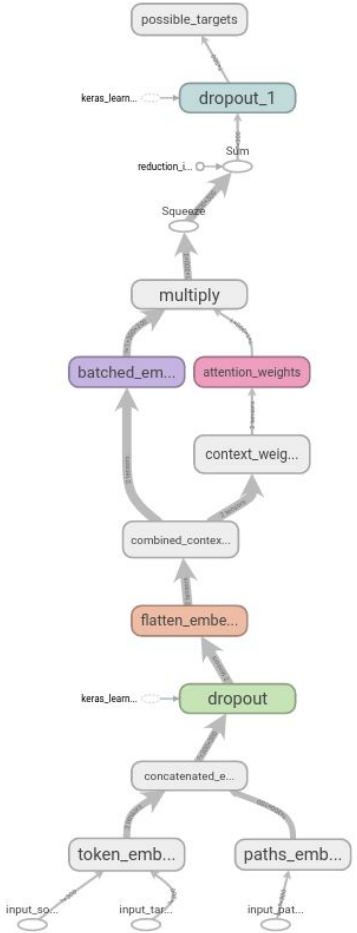

# ТОП-50 идентификаторов

## переменные

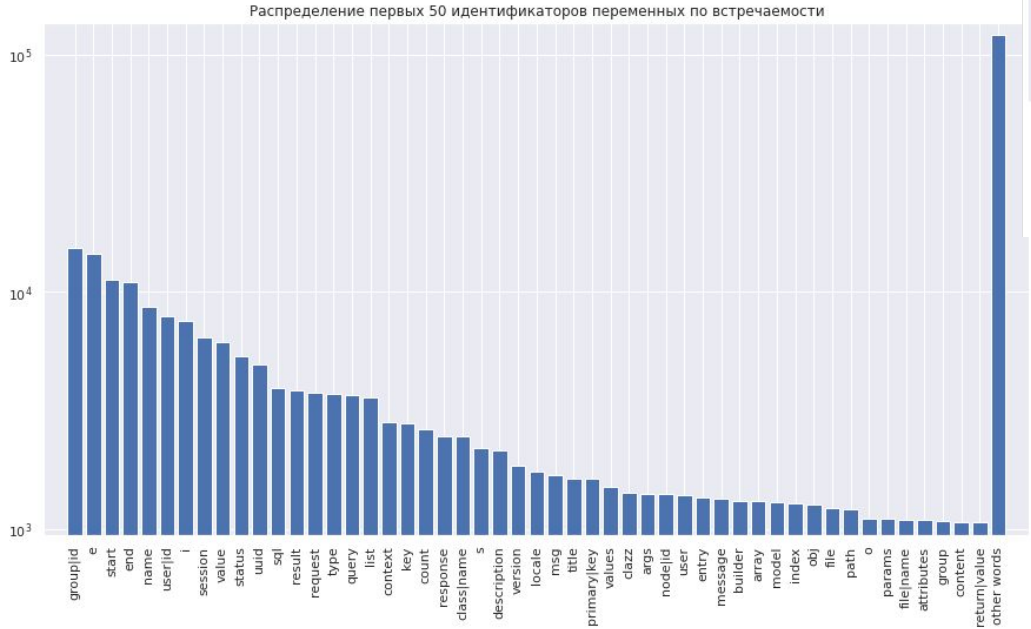


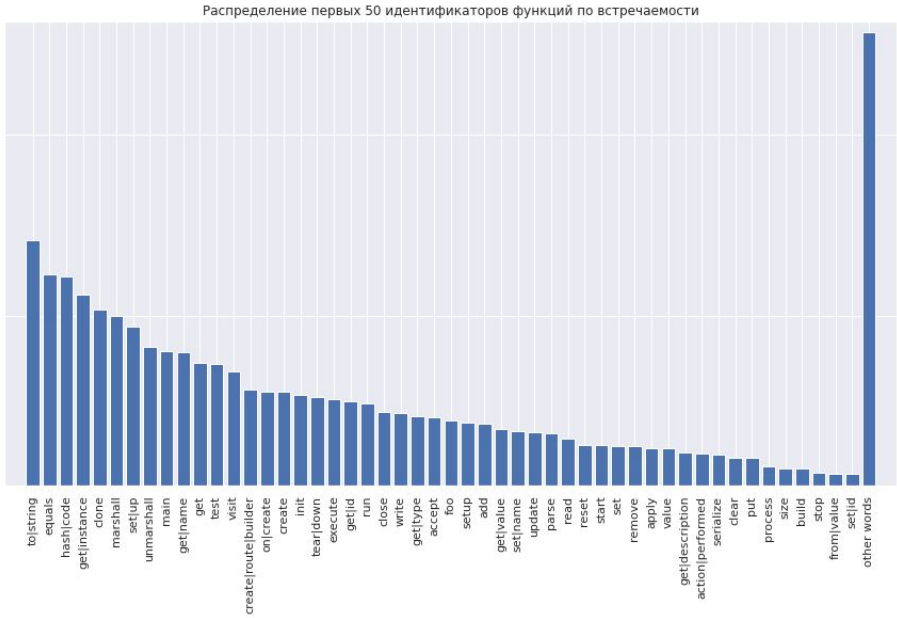


## функции